Universidad Iberoamericana

Materia: Ciencia de Datos

Proyecto: Modelo Predictivo UFC

Autora: Inka Patricia Maya Cusirramos

Profesores: Máximo Eduardo Sánchez Gutiérrez y Alma Rocío Sagaceta Mejía

Asesor: Nelson Omar Muriel Torrero

Fecha: 01 de diciembre del 2025

Índice

Resumen 3
Introducción y Marco Teórico 3
Contexto del problema: 3
Revisión de literatura: 3
Modelos y teorías relevantes: 4
Motivación 6
Metodología 6
Recolección de Datos: 6
Preparación de Datos: 6
Selección de Características: 10
Entrenamiento y Evaluación: 12
Modelos: 12
Métricas de Evaluación: 12
Resultados 13
Análisis de Resultados y Conclusiones 16
Limitaciones: 16
Propuesta de Apuestas Informadas 17
Trabajo a Futuro 17
Referencias 18
Declarativa de uso de IA generativa 20
APPENDIX 20

Resumen

Se busca crear un modelo predictivo de las peleas de la UFC que identifique el ganador, utilice técnicas de ciencia de datos y herramientas actuariales como la probabilidad para lograr precisión en un ambiente complejo y teoría de gestión de riesgos con el fin de optimizar un portafolio de apuestas.

Además, se tiene en vista un enfoque humanista al buscar difundir información para la toma adecuada de decisiones que involucren las finanzas personales de los fanáticos con la esperanza de batallar la ludopatía.

Se usaron técnicas de web scrapping para recolectar los datos de la página oficial de la UFC. A lo largo del proyecto se utilizó la librería de Python sci-kit learn, lo principal fue realizar feature engineering para optimizar el valor de la información, obteniendo al final un dataset con diferencias y ratios de estadísticas progresivas de los peleadores, el sistema de rating ELO y tomando en cuenta las cuotas de las casas de apuestas.

El modelo con mayor accuracy fue XGBoost con 68.68% y 66.62% en test y CV accuracy respectivamente. Se presenta una propuesta de apuestas y se detallan las posibles mejoras futuras.

Introducción y Marco Teórico

Contexto del problema:

Las siglas UFC significan Ultimate Fighting Championship, creada en 1993, es una compañía estadounidense de peleas de artes marciales mixtas, donde practicantes de distintas disciplinas de combate como box, taekwondo, jiu-jitsu, lucha, entre otras se enfrentaban en un torneo de eliminación directa en una sola noche con el objetivo de determinar el arte marcial más efectivo.

En la actualidad la organización está dividida en categorías de peso y sexo, con eventos de aproximadamente 12 peleas, eliminando el componente de torneo en una noche y los peleadores evolucionaron en estilo de combate adaptando técnicas de cada disciplina para crear un estilo más robusto, el estilo MMA, aunque siguen existiendo especialistas y preferencias. [1]

La naturaleza del deporte y en especial del combate es volátil, no es extraño escuchar que la parte menos predilecta gana un encuentro. Por esta razón predecir los resultados se vuelve una tarea complicada, pero podemos acercarnos si escogemos correctamente las variables predictoras.

Revisión de literatura:

Se encontraron varios artículos, de los más relevantes fueron: *Machine Learning approach to predicting Mixed Martial Arts matches* por M. Turgut de la Universidad de

Tilburg [2] y *Data-Driven MMA Outcome Prediction Enhaced by Fighter Styles: A Machine Learning Approach* por Jiajie Yin de la Universidad Normal de Beijing [3]. Ambos obtuvieron los datos de ufcstats.com, la página oficial de la organización que lleva el récord de cada pelea, con técnicas de web scrapping, que se refiere al proceso de recopilar datos de sitios web a través de programas.

Turgut se concentró en prevenir data leakage, un fenómeno común en estudios predictivos de deportes y en general en machine learning. Según el Journal of Big Data, "Data leakage se refiere a la incorporación de información 'ilegítima' en el proceso de entrenamiento de un modelo de aprendizaje automático. Por ejemplo, la fuga ocurre cuando el modelo aprende a partir de información que proviene del conjunto de prueba, el cual se supone que debe permanecer no visto. Por lo tanto, no es posible realizar una evaluación justa del error de generalización, ya que el conjunto de prueba deja de representar datos nuevos y realmente no observados." [Traducción propia del original en inglés] [4].

Mientras que Yin optó por hacer clustering, para identificar los estilos de pelea (striker, grappler y all-rounder) para predecir los resultados de una pelea. "La agrupación en clústeres es un algoritmo de ml no supervisado que organiza y clasifica diferentes objetos, puntos de datos u observaciones en grupos o clústeres basados en similitudes o patrones." [5]. Estos fueron los resultados de cada proyecto:

Tabla 1: Accuracy de modelos según autor

Modelo	M. Turgut	J. Yin
Random Forest	58.98%	62.65%
Neural Network	59.11%	60.12%
SVM	-	59.13%
XGBoost	-	60.64%
Logistic Regression	-	63.99%
Majority Voting	-	65.52%

Modelos y teorías relevantes:

A continuación, se explican los modelos utilizados en los estudios mencionados, además de otros utilizados en este trabajo:

- Random Forest: Modelo que entrena varios árboles de decisión, estos dividen recursivamente los predictores de modo que cada hoja representa un valor predicho [6], y genera la predicción final tomando la clase más común o el promedio de las predicciones de estos árboles.
- Gradient Boosting (GB): Modelo de boosting, donde los árboles de decisión se construyen uno tras otro intentado corregir los errores del anterior. [7]
- Extreme Gradient Boosting (XGBoost): Versión optimizada del GB que añade regularización [7], método para reducir el sobreajuste: cuando el modelo aprende del ruido de los datos de entrenamiento y no de patrones reales.
- Light GBM: Variante de GB diseñado para ser más rápido y eficiente usando crecimiento leaf-wise, expande la hoja que reduce más la pérdida, y agrupando valores de variables con histogramas. [7]
- Majority Voting: Técnica donde varios modelos hacen una predicción y la salida final se decide por la opción más votada.
- Stacked Ensemble: "Técnica que combina múltiples modelos para reducir sus sesgos y mejorar el rendimiento predictivo. Más específicamente, las predicciones de cada modelo (modelos base) se apilan y se utilizan como entrada para un modelo final (meta-modelo) para calcular la predicción." [8]
- Logistic Regression: Modelo de clasificación binaria, estima la probabilidad de que una observación pertenezca a una clase específica, usando la función logística. [9]
- Support Vector Machine (SVM): Modelo de clasificación que busca el hiperplano óptimo que maximice la distancia entre los datos más cercanos de clases opuestas. [10]
- Neural Network: Modelo inspirado en el cerebro humano, que consiste en neuronas que aprenden patrones de los datos ajustando la robustez de sus conexiones. [11]

Por la parte de la optimización de portafolios de apuestas se planea utilizar Kelly Criterion, que indica que fracción de tu capital deberías apostar para evitar la ruina y maximizar el crecimiento.

Otra mención importante son las odds o cuotas de apuestas. En un sentido formal se definen como la probabilidad de éxito sobre la probabilidad de fracaso (p/1-p). En el sentido de casas de apuestas conservan esa definición más el margen de la casa para asegurar ganancias y son útiles para los apostadores, ya que, comunican cuánto te van a pagar si aciertas. Por ejemplo, usando las odds americanas (hay varias convenciones) -150 significa que tienes que apostar 150 para ganar 100, mientras que +150 significa que, si apuestas 100 puedes ganar 150, si tiene negativo es favorito y si tiene positivo es underdog.

Motivación

El proyecto es interesante a un nivel personal porque requiere de la implementación de varios métodos aprendidos a lo largo de la carrera de actuaría para responder a una pregunta compleja usando datos reales y recientes. Le puede interesar a varios agentes, como:

- Casas de apuestas: mejor determinación de probabilidades.
- Peleadores: identificación de puntos de mejora.
- Fanáticos: comprensión más profunda del deporte para hacer decisiones informadas alejándose de la ludopatía.

Metodología

En este proyecto se espera seguir una metodología de Machine Learning:

1. Recolección de Datos
2. Preparación de Datos
3. Selección de Características
4. Entrenamiento y Evaluación

Recolección de Datos:

Ya existen diferentes bases gratis en internet en sitios como Kaggle, comunidad de ciencia de datos, y existen espacios de compraventa de APIs [12]. Se decidió tomar otra ruta e ir a la fuente principal que es la misma compañía UFC [13], esta lleva un registro muy completo de todas las peleas hasta la fecha junto con sus peleadores, pero no tienen una API disponible así que se implementó la técnica de web scrapping para la recolección. Primero se recolectaron los links de cada evento en un archivo de texto, dentro de cada evento se entró a todas las peleas y peleadores recolectando información. Al final se consiguió una base de datos con 8366 filas/peleas y 176 columnas, las cuales contienen: estadísticas de cada pelea, datos de los peleadores, del evento y la pelea. Las variables y su descripción se pueden ver en la tabla A.2 del Apéndice.

Preparación de Datos:

Al hacer el análisis inicial se encontraron algunas columnas con valores vacíos.

Ilustración 1: Heatmap valores faltantes por fila de cada columna. Amarillo indica faltantes.

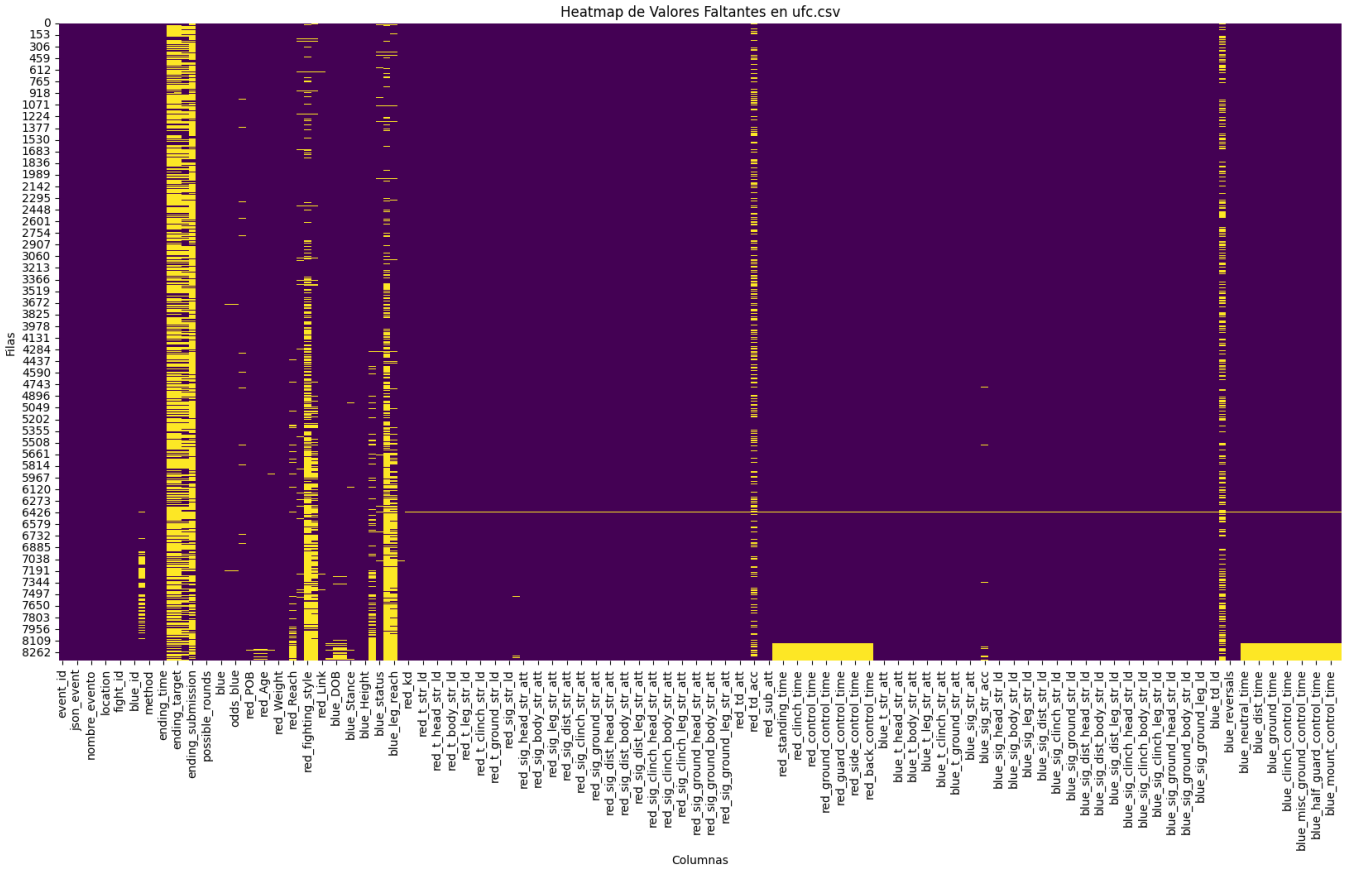

Algunas columnas eran de carácter informativo por lo que no importaba que hubiera faltantes, otras como 'ending strike' tenían sentido, ya que, si la pelea no terminó por knockout no existirá un ending strike, por otro lado, leg reach se eliminó por tener un gran porcentaje de vacíos. También se tuvo en cuenta que las reglas actuales de MMA empezaron hasta UFC 28, por lo que, se eliminaron las filas anteriores.

En las columnas Height, DOB (Date of Birth) y POB (Place of Birth) se optó por imputación manual porque faltaban muy pocos datos. En cambió la columna Reach (alcance de brazos) tenía cientos de faltantes, por lo que, se utilizó la técnica de imputar con la mediana según altura, ya que la altura tiene alta correlación con reach (como se puede ver en la Ilustración 2) y se agregó la columna rematch, que indica el número de veces que los peleadores se habían encontrado en el óctagono anteriormente.

Ilustración 2: Matriz de Correlación

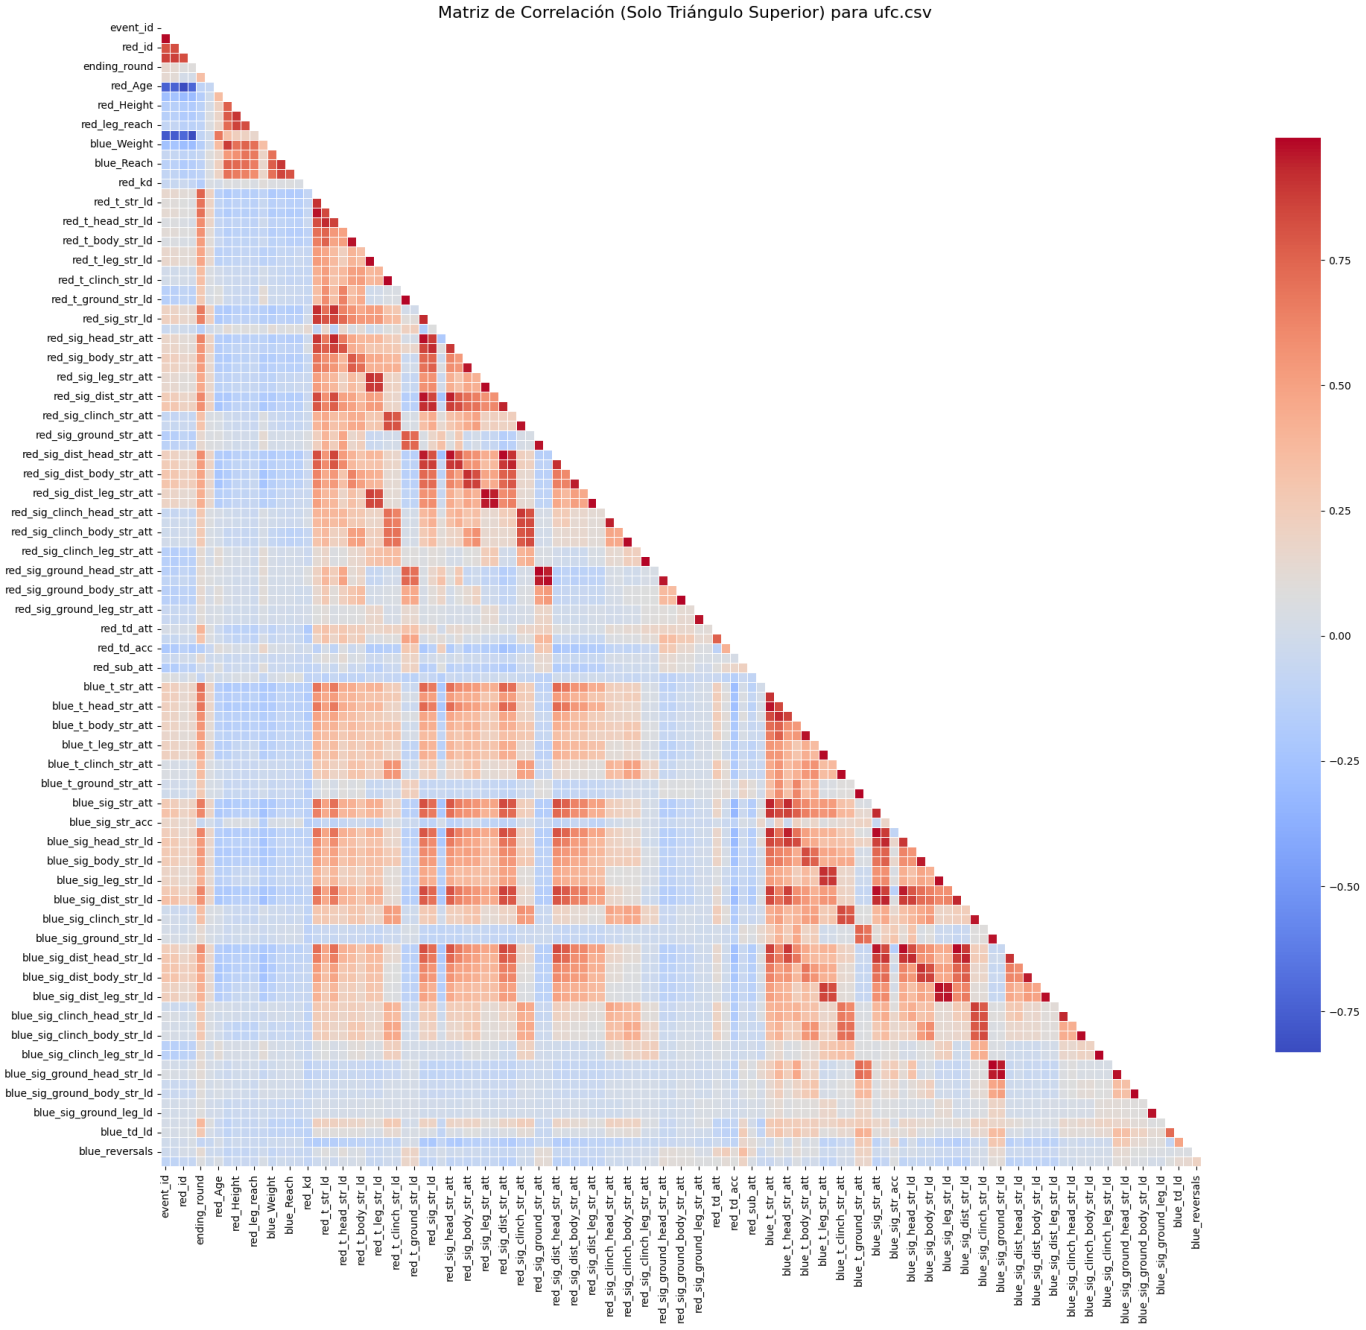

La segunda parte de la preparación de datos es transformarlos. Había unas columnas de tiempo en minutos que se convirtieron a segundos para facilitar cálculos posteriores. Después se realizó feature engineering/ingeniería de características, un proceso de machine learning donde tomas características de la base de datos para crear variables más predictivas. Se modificaron y crearon (explicadas en la Tabla 2) estadísticas de todas las peleas para que fueran progresivas, creemos que estas son de gran importancia, ya que, al analizar una pelea futura solo tienes los datos y estadísticas de los peleadores hasta el momento, es decir, antes de la pelea. Muchos

proyectos para predecir los resultados de la UFC no toman en cuenta esto, resultando en exactitudes demasiado optimistas por data leakage.

Tabla 2: Descripción de nuevas variables

Variable (para red y blue)	Descripción
P_sig_str_acc	Golpes con impacto real en la pelea acertados / Golpes con impacto real en la pelea intentados
P_td_acc	Derribos acertados / Derribos intentados
P_avg_fight_time	Tiempo promedio de pelea en segundos
P_kd_avg_per_fight	Derribos por golpe / Número de peleas
P_sig_str_def	Porcentaje de golpes significativos intentados en contra de un peleador que no son exitosos
P_td_def	Porcentaje de derribos intentados en contra de un peleador que no son exitosos
P_sig_str_standing	Proporción de golpes significativos lanzados estando de pie
P_sig_str_clinch	Proporción de golpes significativos lanzados estando en clinch: posición donde los peleadores están muy cerca, de pie y generalmente con los brazos entrelazados
P_sig_str_ground	Proporción de golpes significativos lanzados estando en el suelo
P_sig_str_head	Proporción de golpes significativos lanzados a la cabeza del oponente
P_sig_str_body	Proporción de golpes significativos lanzados al cuerpo del oponente
P_sig_str_leg	Proporción de golpes significativos lanzados a las piernas del oponente
P_win_by_tko_ko	Proporción de victorias por tko/ko
P_win_by_sub	Proporción de victorias por sumisión
P_win_by_dec	Proporción de victorias por decisión
P_sig_str_ld_per_fight	Golpes significativos acertados / Número de peleas
P_td_avg_per_fight	Derribos / Número de peleas
P_sig_str_abs_per_fight	Golpes significativos acertados por los rivales / Número de peleas

P_sub_avg_per_fight	Sumisiones / Número de peleas

Se pueden consultar las abreviaciones en la Tabla A.1 del Apéndice.

Siguiendo con el feature engineering agregamos ELO, herramienta usada para evaluar la habilidad relativa de competidores donde los enfrentamientos son uno contra uno, actualizandose después de cada combate (siguiendo la filosofía de estadísticas progresivas). [14]

Selección de Características:

Analizando la distribución de la columna winner, se notó que red ganaba más del 90% de los encuentros antes del 2010, una explicación para este fenómeno es que antes de la fecha mencionada simplemente asignaban el color de red a la parte que ya había resultado ganadora, para eliminar este sesgo nos quedamos con las peleas a partir del 2010. También se observó que de los cinco valores posibles para la columna winner; ovrt, cnc y draw eran categorías con mínima frecuencia, para evitar sobreajuste y promover resultados certeros se eliminaron las filas con esos valores.

Ilustración 3: Distribución de columna winner

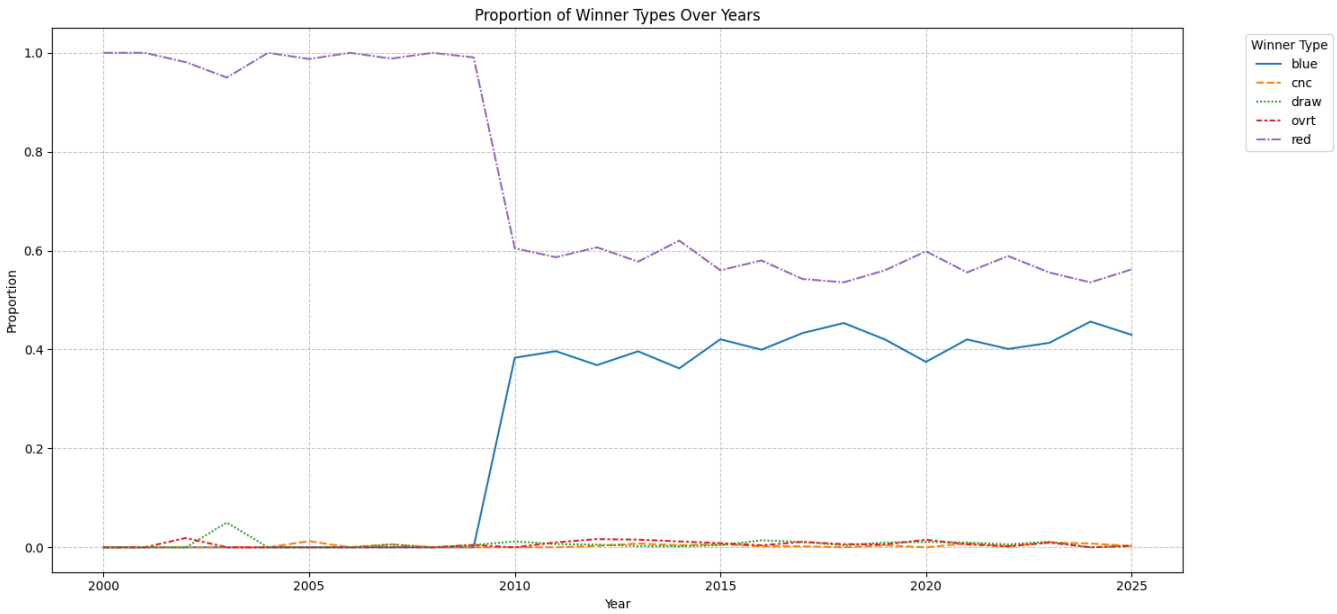

Ilustración 4: Distribución de la columna winner eliminando sesgo

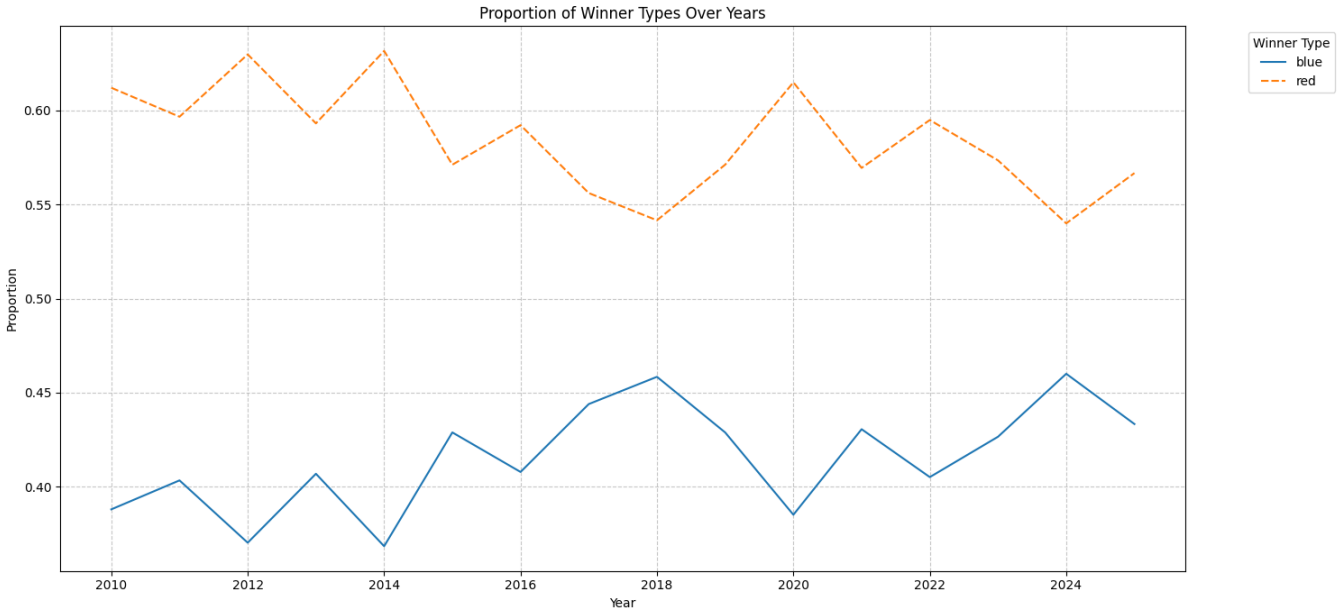

La distribución nos indica que a lo largo de los años red ha ganado de una manera constante sobre su contrincante, esto tiene sentido, ya que, en la UFC casi siempre se le asigna este color al favorito. También podemos inferir que nuestro modelo debe superar, por lo menos, una precisión del 60% para ser valioso.

Por otro lado, se llegó a la conclusión de que no importan tanto las métricas absolutas, si no que tan bueno es un peleador con respecto a otro, por eso se decidió usar variables de comparación entre los dos peleadores, usando diferencias y ratios entre las estadísticas progresivas, odds y elo de la forma: red-blue o red/blue (solo para las variables de accuracy y defense). Logramos evitar la división por color arbitraria, ya que, en una pelea un luchador puede ser rojo y en otra azul y logramos reducir la dimensionalidad del problema. Los valores faltantes de estas nuevas variables fueron imputados con la mediana de su columna respectiva.

La única excepción fueron odds, donde no quisimos imputar, prefiriendo eliminar las filas con valores faltantes. Tomamos esta decisión porque creemos que es el mejor predictor, según la Teoría del Mercado Eficiente, los precios de mercado (cuotas de apuestas) incorporan rápidamente casi toda la información pública disponible, por eso las odds funcionan como un resumen muy compacto del nivel relativo de cada pelador. Sin embargo, el mercado de apuestas deportivas es semi-eficiente, al comparar la probabilidad de que los modelos aplicados contra la probabilidad implícita en las cuotas se pueden detectar oportunidades de valor donde el modelo sea más preciso que el mercado, así explotando pequeñas ineficiencias [15].

El dataset final consiste en 32 columnas y 2,648 filas, las ya mencionadas diferencias y ratios de estadística progresivas entre peleadores, más fight_id, división, rematch, fecha, winner, red y blue.

Entrenamiento y Evaluación:

Para predecir el resultado de peleas de UFC, viéndolo como un problema de clasificación de la columna objetivo winner (red/blue). Se entrenaron varios modelos de clasificación supervisada utilizando un conjunto de datos que incluye 28 variables predictoras numéricas y categóricas.

Para las variables numéricas se utilizó la función StandardScaler para lidiar con el problema de variables con diferentes escalas. Para las variables categóricas se aplicó codificación one-hot encoding, lo que permite que los modelos puedan interpretarlas correctamente.

Dado que los datos están ordenados cronológicamente, para conservar su aspecto progresivo, se usó la validación cruzada TimeSeriesSplit, que respeta el orden durante las divisiones de entrenamiento y prueba, evitando data leakage. Y para cada modelo se realizó una búsqueda aleatoria de hiperparámetros con RandomizedSearchCV, que prueba 15 combinaciones al azar y elige los mejores parámetros, para optimizar su rendimiento en la validación cruzada (CV), este es un método que utiliza todos los datos para entrenar y probar varias veces, dando un promedio más justo de las métricas de evaluación.

Modelos:

Se probaron seis modelos populares, ya explicados en el marco teórico, para clasificación binaria. Su diversidad nos permitirá comparar distintos enfoques.

- Regresión Logística: Es interpetable y sirve como base.
- SVM: Destaca para datos no lineales.
- GB: Las técnicas de boosting son famosas por mejorar la precisión.
- XGBoost: Utiliza técnicas de boosting optimizadas.
- LightGBM: Boosting rápido.
- Stacked Ensamble: Se combinaron las predicciones de los cinco modelos anteriores para entrenar un modelo de regresión logística final.

Métricas de Evaluación:

- Accuracy: Proporciones de predicciones correctas sobre todas las pruebas.
- AUC: Mide la capacidad del modelo para distinguir entre clases. Toma valores entre 0.5 (aleatorio) y 1 (perfecto).
- Matriz de confusión: Tabla que muestra los verdaderos y falsos positivos y los falsos verdaderos y positivos.
- Correlación: Cuantifica la relación lineal entre dos variables numéricas (-1 a 1).
- MAE (Error Absoluto Medio): Calcula el promedio de los errores absolutos entre valore predichos y observados.

Resultados

A continuación, se presenta tablas y gráficas ilustrando los resultados del proyecto. En la siguiente sección se analizan.

Tabla 3: Resultados de Modelos

Modelo	Test Accuracy	CV Accuracy	AUC
Logistic	67.55%	66.08%	0.7478
SVM	67.92%	65.85%	0.7460
GB	67.17%	66.39%	0.7452
XGBoost	68.68%	66.62%	0.7364
LightGBM	65.09%	64.94%	0.7156
Stacked Ensamble	67.36%	-	0.7494

Ilustración 5: Matrices de Confusión para cada modelo

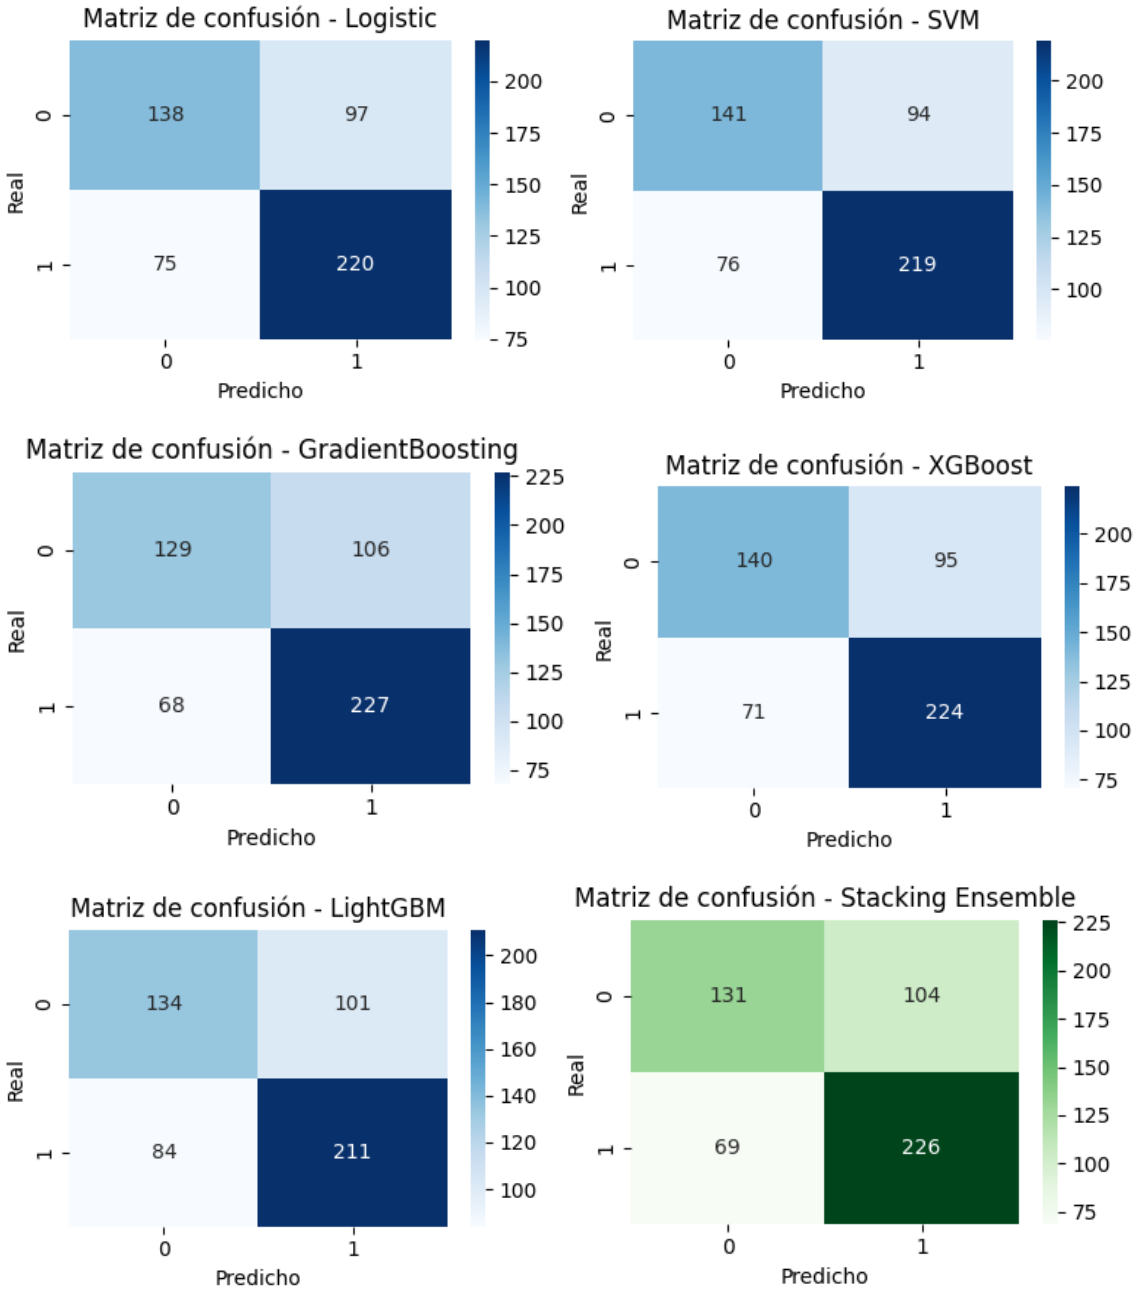

Ilustración 6: 10 Variables más predictivas

feature	importance
num__diff_odds	0.103995
cat__division_Women's Strawweight	0.039476
cat__division_Featherweight	0.036323
cat__division_Women's Flyweight	0.035222
cat__division_Light Heavyweight	0.034512
cat__division_Heavyweight	0.033251
num__diff_Age	0.030015
num__diff_p_sig_str_body	0.029567
num__diff_Weight	0.027983
cat__division_Middleweight	0.026963

Ilustración 7: Comparación de odds vs modelo

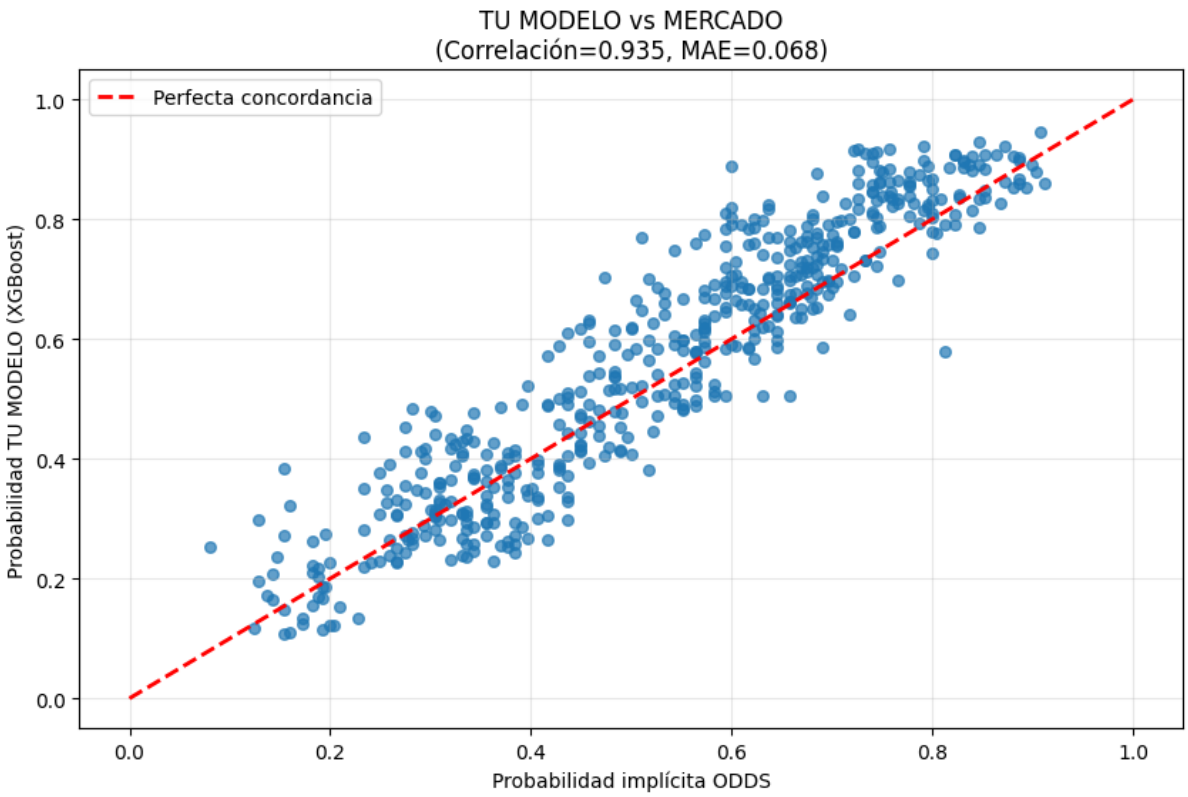

Tabla 4: Peleas con más discrepancia. Porcentajes indican probabilidad de que gane red.

Pelea	Modelo	Mercado	Diferencia (pp)	Resultado	Interpretación
Cortes-Acosta vs Spann (HW)	88.8%	60%	+28.8	HIT, modelo>odds	Value bet exitoso

Abdelwahab vs Pogues (HW)	77%	51.1%	+25.9	HIT, modelo>odds	Value bet exitoso
Aliskerov vs Muniz (MW)	58%	81.2%	-23.2	HIT, odds>modelo	Mercado superior
Silva vs Van (FW)	38.4%	15.3%	+23	HIT, odds>modelo	Mercado superior
Chiesa vs Griffin (WW)	70.2%	47.4%	+22.8	HIT, modelo>odds	Value bet exitoso

Análisis de Resultados y Conclusiones

Los modelos mostraron resultados similares en accuracy, entre 65% y 69%, con XGBoost alcanzado el mayor resultado. Todas las puntuaciones de AUC > 0.7 lo que indica buena capacidad para discriminar ganadores.

Podemos ver en las matrices de confusión, que casi todos los modelos predicen bien el cuadrante inferior derecho, predicen red ganador y si lo es, es más seguro apostar a red si el modelo predice red que en el caso de azul. Y tienen más falsos positivos para azul, probablemente por el desbalance en distribución, no es tan bueno prediciendo upsets.

Tenemos una correlación de 0.935 respecto a las odds del mercado y una MAE de 0.068 (visualizadas en Ilustración 7), lo que inicialmente puede indicar que el modelo solo copiaba las probabilidades del mercado, indicando que estamos en un mercado eficiente. Sin embargo, el análisis de variables más predictivas (Ilustración 6) reveló que las odds, aunque la más importante, solo aportan 10.4%, el 90% restante proviene de estadísticas de peleas, características físicas y categorías de peso. Surgiendo la hipótesis que la alta correlación se debe a convergencia informacional en lugar de copia directa.

Esta hipótesis se apoya por el análisis de las cinco peleas más discrepas, donde el modelo difiero más de 20 pp (puntos porcentuales) mostró un patrón de ganarle a las odds en ciertas ocasiones, sugiriendo nichos de oportunidad donde el mercado aún no es eficiente.

Limitaciones:

- Desbalance: Los favoritos (rojos) suelen ganar, inflando accuracy
- Peleas muy antiguas pueden no capturar la realidad actual
- Tamaño del dataset
- Falta de variables contextuales (lesiones, cambios de campamento, short notice, etc.)

Propuesta de Apuestas Informadas

Otra parte fundamental del proyecto es la aplicación del conocimiento recabado en fin de batallar la ludopatía. Aquí se presenta una estrategia para evitar la ruina financiera, tomando de ejemplo las peleas con más discrepancia (Tabla 4).

Kelly Criterion es una fórmula matemática que indica el porcentaje de dinero que se debe apostar para maximizar crecimiento sin arriesgar la ruina. También se usa una variante, el llamado Kelly Fraccionado para perfiles más conservadores, típicamente apostar ¼ del % de Kelly. Y para perfiles aún más consevadores se puede agregar un límite de seguridad máximo de % de Kelly. [16]

Kelly % = (probabilidad de modelo x odds - 1) / (odds -1)

Tabla 5: Ejemplo Criterio de Kelly empezando con $1,000

Pelea	Modelo	Mercado	Kelly	Kelly F.	Apuesta	Ganancia	Bankroll
Cortes-Acosta vs Spann	88.8%	60%	72%	18%	$180	$120.60	1,120.60
Abdelwahab vs Pogues	77%	51.1%	53%	13.25 %	$148.50	$142.60	1,263.20
Aliskerov vs Muniz	58%	81.2%	-124 %	-	Pasar	-	1,263.20
Silva vs Van	38.4%	15.3%	-152 %	-	Pasar	-	1,263.20
Chiesa vs Griffin	70.2%	47.4%	43%	10.75 %	$135.8	$150.8	$1,414

Trabajo a Futuro

Algo muy importante es averiguar el accuracy por división con el fin de encontrar nichos de ineficiencia del mercado. Calcular el win rate en las discrepancias del modelo con odds >15%.

Para aumentar la exactitud del modelo lo más importante es feature engineering, podemos intentar probar otro tipo de variables y seguir indagando en la literatura. También se pueden añadir otras variables, como: sentimientos en redes sociales, streaming de datos en tiempo real, recolectar odds de otras casas de apuestas y estadísticas por ronda en vez de por toda la pelea. Además, se podría pensar en expandir el alcance del modelo predictivo a otras áreas. Y se podría indagar en

submercados de las apuestas de MMA como predecir el método de victoria, ending round, etc.

Hay oportunidades de optimizar el pipeline para hacer predicciones frecuentes, a la mano de actualizar el modelo conforme pasen los eventos. Se puede mejorar la propuesta de apuestas añadiendo VaR y simulaciones Montecarlo para simular el ROI (Return on Investment). Y se espera hacer difusión masiva de los resultados para alentar decisiones informadas como contraparte a la ludopatía.

Referencias

[1] UFC Español, "History of UFC," UFCespanol.com. [Online]. Available: https://www.ufcespanol.com/history-ufc (accessed Nov. 30, 2025).

[2] M. Turgut, "Machine Learning approach to predicting Mixed Martial Arts matches," M.Sc. thesis, Tilburg University, 15 enero 2021. [En línea]. Disponible en: http://arno.uvt.nl/show.cgi?fid=156304

[3] J. Yin, "Data-Driven MMA Outcome Prediction Enhanced by Fighter Styles: A Machine Learning Approach," in Proc. 4th Int. Conf. Machine Learning and Intelligent Systems Engineering (MLISE), 2024. [En línea]. Disponible en: https://jjthehonest.github.io/files/MLISE2024.pdf

[4] L. Sasse, E. Nicolaisen-Sobesky, J. Dukart, et al., "Overview of leakage scenarios in supervised machine learning," J. Big Data, vol. 12, p. 135, 2025. [En línea]. Disponible en: https://journalofbigdata.springeropen.com/articles/10.1186/s40537-025-01193-8

[5] IBM, "¿Qué es la agrupación en clústeres?", IBM Think. [En línea]. Disponible en: https://www.ibm.com/mx-es/topics/clustering

[6] IBM, "What is a Decision Tree?", IBM Think, 2025. [En línea]. Disponible en: https://www.ibm.com/think/topics/decision-trees

[7] "GradientBoosting vs AdaBoost vs XGBoost vs CatBoost vs LightGBM," GeeksforGeeks, last updated 23 Jul. 2025. [Online]. Available: https://www.geeksforgeeks.org/machine-learning/gradientboosting-vs-adaboost-vs-xgboost-vs-catboost-vs-lightgbm/ (accessed Nov. 30, 2025).

[8] J. Amat Rodrigo and J. Escobar Ortiz, "Stacking ensemble de modelos de forecasting," Cienciadedatos.net. [En línea]. Disponible: https://www.cienciadedatos.net/documentos/py52-stacking-ensemble-modelos-forecasting. (Accedido: 30-Nov-2025).

[9] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: With Applications in Python*. New York, NY, USA: Springer, 2023. doi: 10.1007/978-1-0716-3342-9.

[10] IBM, “What is a Support Vector Machine?”, IBM Think. [En línea]. Disponible en: https://www.ibm.com/mx-es/think/topics/support-vector-machine (accedido: 30-Nov-2025).

[11] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. [Online]. Available: http://www.deeplearningbook.org/

[12] RapidAPI, “mma-api1”, RapidAPI Hub. [En línea]. Disponible en: https://rapidapi.com/belchiorarkad-FqvHs2EDOtP/api/mma-api1 (accedido: 30-Nov-2025)

[13] UFC, “Events,” UFC.com [Online]. Available: https://www.ufc.com/events (accedido: 12-Sept-2025).

[14] “Elo rating system”, Wikipedia. Disponible en: https://en.wikipedia.org/wiki/Elo_rating_system. (accedido: 30-Nov-2025).

[15] “Efficient Market Hypothesis (EMH): explained simply,” Investopedia. [Online]. Available: https://www.investopedia.com/articles/basic/04/022004.asp (accessed Nov, 30, 2025).

[16] Pinnacle, "Nueva mirada al criterio de Kelly: evaluación del riesgo," Pinnacle, 2024. [Online]. Disponible: https://www.pinnacle.com/es/betting-articles/betting-strategy/kelly-criterion-risk-assessment/nj2jwgv9yhxjp6gj

Declarativa de uso de IA generativa

Declaratoria de uso de IA generativa

(versión: agosto/2025, adaptada a Ciencia de Datos)

Bajo protesta de decir verdad, declaro/declaramos que el presente trabajo ha sido realizado bajo las siguientes condiciones en relación con el empleo de aplicaciones y recursos de inteligencia artificial (IA) generativa:

Señalar todas las opciones que apliquen	**Marcar con X**
No ha habido uso alguno de IA	
Corregir redacción y/o ortografía	
Acomodo / Estructuración / Formateo del texto	
Obtención de datasets a través de IA (incluyendo generación de datos sintéticos)	
Procesamiento de datos	X
Análisis exploratorio de datos (EDA)	X
Visualización de datos (tablas, gráficas, dashboards)	X
Generación de código (Python, R, SQL, etc.)	X
Depuración/optimización de código	X
Modelado predictivo con técnicas de machine learning	X
Interpretación de resultados estadísticos o métricas de modelos	X
Reflexión sobre ética y sesgos en el uso de datos y modelos	
Búsqueda de información *	X
Redacción de entre un 1 y 25% del texto	X
Redacción de entre un 25 y 50% del texto	
Redacción de más del 51% del texto	

* Consciente(s) de que la IA generativa tiene una tendencia intrínseca a generar respuestas que no corresponden con la verdad (alucinaciones), yo/nosotros,

Inka Patricia Maya Cusirramos

declaro haber validado y comprobado la veracidad de lo que he(mos) obtenido a partir de estas herramientas y asumo/asumimos plenamente la responsabilidad del contenido del trabajo que estoy/estamos entregando.

IMPORTANTE: Esta declaración es únicamente informativa y no tendrá ningún impacto en la evaluación del trabajo

APPENDIX

Tabla A.1: Diccionario de abreviaturas para variables

Abreviatura	Significado
POB	Place of Birth/Lugar de Nacimiento
DOB	Date of Birth/Fecha de Nacimiento
kd	Knockdown/Caída por golpe
t	Total
str	Strike/Golpe
att	Attempted/Intentado
ld	Landed/Acertdo
sig	Significant/Significante

acc	Accuracy/Exactitud
dist	Distance/A distancia
td	Takedown/Derribo
sub	Submission/Sumisión. Cuando un peleador obliga a su rival a rendirse mediante una técnica de estrangulamiento o llave articular.
misc	Miscelanous/Misceláneo u Otros
KO	Knockout
TKO	Technical Knockout
P	Progressive/Progresivos. Quiere decir que acumula las estadísticas hasta antes de la pelea evaluada
Avg	Average/Promedio
def	Defense/Defensa
abs	Absorbed/Recibidos

Tabla A.2: Descripción de variables del primer dataset. Variables que empiezan con red_ tienen su equivalente en blue_. En algunas filas se omite la descripción por obviedad.

Variable	Descripción
event_id	Clave única por evento
event_url	Link para la página principal del evento
json_event	Link para visualizar el formato json (JavaScript Object Notation) del evento
json_fight	Link para visualizar el formato json (JavaScript Object Notation) de la pelea más especificada
nombre_evento	
fecha	
location	Donde tomo lugar el evento, en formato: Estado, País
venue	
fight_id	Clave única por pelea
red_id	Clave única del peleador rojo
blue_id	Clave única del peleador azul
segment	Main/Prelims 1/Prelims 2
method	Forma de ganar la pelea: Decision/Submission/KO-TKO
ending_round	1-5
ending_time	0:00-5:00
ending_strike	Si se terminó por KO/TKO se especifica que parte del cuerpo del ganador lo causo

ending_target	Si se terminó por KO/TKO se especifica que parte del perdedor fue la última en ser golpeada
ending_position	From Back Control/From Guard/From Mount/At Distance/On Ground/In Clinch/From Bottom Guard/Standing/Standing Back Control/From Side Control/After Drop to Ground
ending_submission	Si se terminó por sumisión, cuál fue la técnica utilizada
division	División de peso
possible_rounds	1-5
red	Nombre del peleador rojo
blue	Nombre del peleador azul
odds_red	Formato de cuotas de apuestas deportivas, indican cuando puedes ganar si apuestas a red
odds_blue	Formato de cuotas de apuestas deportivas, indican cuando puedes ganar si apuestas a blue
winner	Indica el resultado de la pelea: red, blue, nc (no contest), ovrt (overturned), draw
red_POB	
red_DOB	
red_Age	
red_Stance	Orthodox/Southpaw/Switch
red_Weight	
red_Height	
red_Reach	
red_status	Active/Not Fighting
red_fighting_style	Arte marcial predilecta
red_leg_reach	
red_Link	Link para la página de UFC del peleador
red_kd	
red_t_str_att	
red_t_str_ld	
red_t_head_str_att	
red_t_head_str_ld	
red_t_body_str_att	
red_t_body_str_ld	
red_t_leg_str_att	
red_t_leg_str_ld	
red_t_clinch_str_att	
red_t_clinch_str_ld	
red_t_ground_str_att	

red_t_ground_str_ld	
red_sig_str_att	
red_sig_str_ld	
red_sig_str_acc	
red_sig_head_str_att	
red_sig_head_str_ld	
red_sig_body_str_att	
red_sig_body_str_ld	
red_sig_leg_str_att	
red_sig_leg_str_ld	
red_sig_dist_str_att	
red_sig_dist_str_ld	
red_sig_clinch_str_att	
red_sig_clinch_str_ld	
red_sig_ground_str_att	
red_sig_ground_str_ld	
red_sig_dist_head_str_att	
red_sig_dist_head_str_ld	
red_sig_dist_body_str_att	
red_sig_dist_body_str_ld	
red_sig_dist_leg_str_att	
red_sig_dist_leg_str_ld	
red_sig_clinch_head_str_att	
red_sig_clinch_head_str_ld	
red_sig_clinch_body_str_att	
red_sig_clinch_body_str_ld	
red_sig_clinch_leg_str_att	
red_sig_clinch_leg_str_ld	
red_sig_ground_head_str_att	
red_sig_ground_head_str_ld	
red_sig_ground_body_str_att	
red_sig_ground_body_str_ld	
red_sig_ground_leg_str_att	
red_sig_ground_leg_ld	
red_td_att	
red_td_ld	
red_td_acc	
red_reversals	Un reversal ocurre cuando un peleador en posición desfavorable logra cambiar la situación y quedar en una posición dominante
red_sub_att	
red_neutral_time	
red_standing_time	
red_dist_time	
red_clinch_time	

red_ground_time	
red_control_time	
red_clinch_control_time	
red_ground_control_time	
red_misc_ground_control_time	
red_guard_control_time	
red_half_guard_control_time	
red_side_control_time	
red_mount_control_time	
red_back_control_time	